

PACD

Projeto Aplicado em Ciência de Dados

3º Ano - 1º semestre



Planeamento

Aula	Plano	
1	Introdução à UC; Análise preliminar de dados	
2	Visualização de dados: Boxplots e DBSCAN	
3	Seleção de atributos; Aprendizagem Supervisionada	Quiz 1
4	Aprendizagem Supervisionada e Interpretação de resultados	Quiz 2
5	Engenharia de atributos	
6	Tópicos sobre seleção de modelos, Relatório de Análise de dados, exercícios	Teste intercalar
	Semana Intercalar	
7	Text Mining, NLP, Transformadores e modelos pré-treinados	
8	Tutoria	
9	Tutoria	
10	Tutoria	
11	Tutoria	Entrega relatórios
12	Workshop: Apresentações	

Funcionamento

- O grupo prepara uma **descrição sumária do progresso semanal**, indicando também **desafios e limitações encontradas**
- O **responsável semanal** é nomeado ou “eleito” em rotatividade
 - Deve apresentar o **progresso da semana**, as questões entretanto surgidas e o plano para a semana seguinte (pitch 5m)
 - Deve estar preparado para discutir opções
- A equipa deve **apoiar** a pessoa responsável nessa semana
- A resolução das questões será discutida em aula
 - Tal não impede que, se necessário, que se possa acordar com o docente tratar de alguma situação anormal fora do tempo de aula





Some hints

Slides based on materials produced by Luís Nunes (Iscte)

Understand the Problem

- look at the available data
- Read about the problem
- Talk to experts
- Search for related data that can be used
- Test (when possible)
- ...




Data Quality Assessment

- Number of records
- Number of attributes (or features)
- Attribute data types
 - nominal, ordinal, or continuous.
- Missing values
- Well-formedness:
 - unstructured => structured
- Inconsistency: values are in range, ...
- Calculated values are well-defined



Explore data



Pre-processing

- data cleaning: fill in missing values; detect and remove noisy data and outliers.
- data transformation: normalize data to reduce dimensions and noise; decompose/aggregate
- data reduction: if possible, reduce the data sample set (time efficiency) and balance classes
- data discretization: convert continuous into categorical attributes
- cleaning: remove embedded characters;



Missing Values

- If possible, identify why are they missing ...
then choose ...
- deletion:
 - just remove the records with missing values;
- substitution:
 - dummy (e.g: unknown – categorical; 0 (zero) – numerical)
 - averaged value (e.g.: geometric mean – numerical)
 - (most) frequent value
 - regression



Class imbalance

- Under-sample
 - Stratified
- Oversample
 - SMOTE
 - Random Oversampling
 - AdaSYN
 - ...
- **Do not use oversampled data to test or validate**





Base de dados da ANSR

Acidentes rodoviários nas várias regiões do país

Acidentes rodoviários nas várias regiões do país

- Ficheiros excel relativo ao período 2010 a 2019 e também 2023
 - Em processo de obter os dados de 2024
- Tabelas
 - **Condutores de veículos** - 30 Dias_Cond_Veic (55K registos em 2019)
 - **Passageiros** - 30 Dias_Passag (11K registos em 2019)
 - **Acidentes** - 30 Dias _ Acidentes (26K registos em 2019)
 - **Peões** - 30 Dias_Peões (6K registos em 2019)

Acidentes rodoviários

30 Dias_Cond_Veic (55K registos em 2019)

Id. Acidente	20191684872	20191654557	20191652791	20191684737
Datahora	2019:01:01 00:03:00	2019:01:01 00:55:00	2019:01:01 01:00:00	2019:01:01 01:00:00
Sexo	Masculino	Masculino	Feminino	Masculino
Lesões a 30 dias	Ferido leve	lleso	Ferido leve	Ferido leve
Licença Condução	Com licença/ carta adequada ao veiculo	NÃO DEFINIDO	Com licença/ carta adequada ao veiculo	Com licença/ carta adequada ao veiculo
Teste Alcool	Submetido ao teste do álcoolomia	Submetido ao teste do álcoolomia	Submetido ao teste do álcoolomia	Não submetido condutor não contactado na altura do acidente
Acções Condutores	Em marcha normal	NÃO DEFINIDO	Em marcha normal	Em marcha normal
Inf. Comp. a Acções e Manobras	Obstáculo imprevisto na faixa de rodagem	NÃO DEFINIDO	Não identificada	Não identificada
Nomeoutrosfactores	Normal	Normal	Normal	Normal
Tempo Condução Continuada	Menos de 1 hora	NÃO DEFINIDO	Menos de 1 hora	Menos de 1 hora
Acessórios Condutores	Cinto de segurança	NÃO DEFINIDO	Cinto de segurança	Cinto de segurança
Categoria Veículos	Automóvel ligeiro	Automóvel ligeiro	Automóvel ligeiro	Automóvel ligeiro
Tipo Veiculo	Passageiros	Passageiros	Passageiros	Passageiros
Tipo Serviço	Particular	Particular	Particular	Particular
Veiculo Especial	NÃO DEFINIDO	NÃO DEFINIDO	NÃO DEFINIDO	NÃO DEFINIDO
Ano matrícula	2018	1998	2007	2009
Inspecção Periódica	Válida	Válida	Válida	Válida
Certificado Adr	NÃO DEFINIDO	NÃO DEFINIDO	NÃO DEFINIDO	NÃO DEFINIDO
Carga Lotação	Sem carga	Sem carga	Sem carga	Sem carga
Pneus	Sem deficiência	Sem deficiência	Sem deficiência	Sem deficiência
Seguros	Com seguro	Com seguro	Com seguro	Com seguro
Distrito	Aveiro	Porto	Lisboa	Porto
Concelho	Santa Maria da Feira	Porto	Loures	Maia
Condutor Gr.Etario(<=5) SUM	0	0	0	0
Condutor Gr.Etario(6-9) SUM	0	0	0	0
Condutor Gr.Etario(10-14) SUM	0	0	0	0
Condutor Gr.Etario(15-17) SUM	0	0	0	0
Condutor Gr.Etario(18-20) SUM	0	0	0	0
Condutor Gr.Etario(21-24) SUM	0	0	0	0
Condutor Gr.Etario(25-29) SUM	1	0	0	0
Condutor Gr.Etario(30-34) SUM	0	0	0	1
Condutor Gr.Etario(35-39) SUM	0	1	0	0
Condutor Gr.Etario(40-44) SUM	0	0	0	0
Condutor Gr.Etario(45-49) SUM	0	0	1	0
Condutor Gr.Etario(50-54) SUM	0	0	0	0
Condutor Gr.Etario(55-59) SUM	0	0	0	0
Condutor Gr.Etario(65-69) SUM	0	0	0	0
Condutor Gr.Etario(70-74) SUM	0	0	0	0
Condutor Gr.Etario(>=75) SUM	0	0	0	0
Condutor Gr.Etario(Não Def.) SUM	0	0	0	0

Acidentes rodoviários

30 Dias_Passag (11K registos em 2019)

Id. Acidente	20191712233	20191670105	20191670105	20191670128
Datahora	2019:06:18 17:00:00	2019:03:30 18:15:00	2019:03:30 18:15:00	2019:04:03 17:20:00
Entidades Fiscalizadoras	Polícia de Segurança Pública	Polícia de Segurança Pública	Polícia de Segurança Pública	Polícia de Segurança Pública
Id. Passageiro	1	1	2	1
Lesões a 30 dias	Ferido leve	Ferido leve	Ferido leve	Ferido leve
Sexo	Feminino	Masculino	Feminino	Feminino
Posição Veiculo	Desconhecido	À frente	À retaguarda	À frente
Acessórios Passageiro	C/ capacete/ cinto segurança	C/ capacete/ cinto segurança	C/ sistema retenção de crianças	C/ capacete/ cinto segurança
Distrito	Vila Real	Lisboa	Lisboa	Viana do Castelo
Concelho	Chaves	Oeiras	Oeiras	Viana do Castelo
Passageiro Gr.Etario(<=5) SUM	0	0	0	0
Passageiro Gr.Etario(6-9) SUM	0	0	1	0
Passageiro Gr.Etario(10-14) SUM	1	0	0	0
Passageiro Gr.Etario(15-17) SUM	0	0	0	0
Passageiro Gr.Etario(18-20) SUM	0	0	0	1
Passageiro Gr.Etario(21-24) SUM	0	0	0	0
Passageiro Gr.Etario(25-29) SUM	0	1	0	0
Passageiro Gr.Etario(30-34) SUM	0	0	0	0
Passageiro Gr.Etario(35-39) SUM	0	0	0	0
Passageiro Gr.Etario(40-44) SUM	0	0	0	0
Passageiro Gr.Etario(45-49) SUM	0	0	0	0
Passageiro Gr.Etario(50-54) SUM	0	0	0	0
Passageiro Gr.Etario(55-59) SUM	0	0	0	0
Passageiro Gr.Etario(60-64) SUM	0	0	0	0
Passageiro Gr.Etario(65-69) SUM	0	0	0	0
Passageiro Gr.Etario(70-74) SUM	0	0	0	0
Passageiro Gr.Etario(>=75) SUM	0	0	0	0
Passageiro Gr.Etario(Não Def.) SUM	0	0	0	0

Acidentes rodoviários

30 Dias_ Acidentes (26K registos em 2019)

Id. Acidente	20191684872	20191654557	20191652791
Datahora	2019:01:01 00:03:00	2019:01:01 00:55:00	2019:01:01 01:00:00
Dia	01/01/00	01/01/00	01/01/00
Mês	01/01/00	01/01/00	01/01/00
Hora	01/01/00	01/01/00	01/01/00
Entidades Fiscalizadoras	Guarda Nacional Republicana	Polícia de Segurança Pública	Polícia de Segurança Pública
Velocidade local	50	50	50
Velocidade geral	50	90	50
Dia da Semana	Terça-Feira	Terça-Feira	Terça-Feira
Latitude GPS	40,907580	41,181257	0,0
Longitude GPS	-8,548013	-8,584378	0,0
Num. Mortos a 30 dias	0	0	0
Num. Feridos graves a 30 dias	0	0	0
Num. Feridos ligeiros a 30 dias	1	2	1
Características Técnicas1	Estrada sem separador	Outra via	Estrada sem separador
Cond Aderência	Seco e limpo	Seco e limpo	Seco e limpo
Distrito	Aveiro	Porto	Lisboa
Concelho	Santa Maria da Feira	Porto	Loures
Freguesia	União das freguesias de São Miguel do Souto e Mosteirô	Paranhos	Loures
Pov. Proxima	Macieira de Souto	Porto	Montemor
Nome arruamento	Rua da Póvoa 352		Rua Major Rosa Bastos
Tipos Vias	Arruamento	Outra Via	Arruamento
Cod Via	0	0	0
Estado Conservação	Em bom estado	Em bom estado	Em estado regular
Km			
Factores Atmosféricos	Bom tempo	Bom tempo	Bom tempo
Reg Circulação1	Dois sentidos	Dois sentidos	Dois sentidos
Intersecção Vias	Fora da intersecção	NÃO DEFINIDO	Em entroncamento
Localizações	Dentro das localidades	Fora das localidades	Dentro das localidades
Luminosidade	Noite, com iluminação	Noite, com iluminação	Noite, com iluminação
Marca Via	Sem marcas rodoviárias ou pouco visíveis	Com marcas - separadoras de sentido e de vias de trânsito	Com marcas - separadoras de sentido e de vias de trânsito
Natureza	Colisão com veículo ou obstáculo na faixa de rodagem	Colisão lateral com outro veículo em movimento	Colisão lateral com outro veículo em movimento
Obras Arte	NÃO DEFINIDO	Viaduto/Ponte	NÃO DEFINIDO
Obstáculos	Inexistentes	Inexistentes	Inexistentes
Sentidos	NÃO DEFINIDO	No sentido crescente da quilometragem	NÃO DEFINIDO
Sinais	NÃO DEFINIDO	Outros	Outros
Sinais Luminosos	Inexistentes	Inexistentes	Inexistentes
Tipo Piso	Betuminoso	Betuminoso	Betuminoso
Traçado 1	Recta	Curva	Curva
Traçado 2	Com inclinação	Com inclinação	Com inclinação
Traçado 3	Berma não pavimentada	Sem berma ou impraticável	Berma pavimentada
Traçado 4	Em plena via	Em plena via	Em plena via
Via Trânsito	Direita	Direita	Direita

Acidentes rodoviários

30 Dias_Peões (6K registos em 2019)

Id. Acidente	20191742638	20191665993	20191663203	20191741940
Freguesia	Friões	União das freguesias do Seixal, Arrentela e Aldeia de Paio Pires	São João da Madeira	Campolide
Tipo Natureza	Despiste	Atropelamento	Atropelamento	Atropelamento
Natureza	Despiste com capotamento	Atropelamento de peões	Atropelamento de peões	Atropelamento de peões
Datahora	2019:08:10 19:45:00	2019:03:05 19:30:00	2019:02:19 17:15:00	2019:09:06 15:30:00
Entidades Fiscalizadoras	Guarda Nacional Republicana	Polícia de Segurança Pública	Polícia de Segurança Pública	Polícia de Segurança Pública
Id. Peao	1	1	1	1
Sexo	Feminino	Masculino	Masculino	Masculino
Acções Peão	Transitando pela berma ou passeio	Atravessando em passagem sinalizada	Atravessando em passagem sinalizada	Atravessando fora da passagem de peões a mais de 50m de uma passagem ou quando não exista passagem
Distrito	Vila Real	Setúbal	Aveiro	Lisboa
Concelho	Valpacos	Seixal	Sao Joao da Madeira	Lisboa
Lesões a 30 dias	Ferido leve	Ferido leve	Ferido leve	Ferido leve
Peao Gr.Etario(<=5) SUM	0	0	0	0
Peao Gr.Etario(6-9) SUM	0	0	0	0
Peao Gr.Etario(10-14) SUM	1	0	0	0
Peao Gr.Etario(15-17) SUM	0	0	0	0
Peao Gr.Etario(18-20) SUM	0	0	0	0
Peao Gr.Etario(21-24) SUM	0	0	0	0
Peao Gr.Etario(25-29) SUM	0	0	0	0
Peao Gr.Etario(30-34) SUM	0	0	0	0
Peao Gr.Etario(35-39) SUM	0	1	0	0
Peao Gr.Etario(40-44) SUM	0	0	0	1
Peao Gr.Etario(45-49) SUM	0	0	0	0
Peao Gr.Etario (50-54) SUM	0	0	0	0
Peao Gr.Etario (55-59) SUM	0	0	0	0
Peao Gr.Etario (60-64) SUM	0	0	0	0
Peao Gr.Etario (65-69) SUM	0	0	0	0
Peao Gr.Etario (70-74) SUM	0	0	1	0
Peao Gr.Etario (>=75) SUM	0	0	0	0
Peao Gr.Etario(Não Def.)				
SUM	0	0	0	0